



# Rendimiento Académico Estudiantil

Diagnóstico de calidad, análisis exploratorio y preparación reproducible de datos previo al modelado predictivo del rendimiento final (FinalGrade).

**5.100**

REGISTROS ORIGINALES

**11**

VARIABLES

**5**

PROGRAMAS ACADÉMICOS

Cristóbal Soto Vidal · Martín Romero Álvarez · Benjamín Paredes Aguayo · Darío Silva Pedreros

Asignatura Inteligencia Artificial (620454) · Universidad del Bío-Bío · Septiembre 2026

# Contexto y objetivo del trabajo

¿Por qué auditar la calidad de los datos antes de analizarlos?

## El problema

Una institución de educación superior desea comprender qué factores explican el rendimiento académico de sus estudiantes (FinalGrade). Antes de analizar o modelar, es indispensable determinar si el dataset presenta problemas de calidad que puedan sesgar las conclusiones: valores faltantes, duplicados, inconsistencias de dominio y outliers.

## Objetivo

- Diagnosticar la calidad del dataset crudo
- Realizar un análisis exploratorio (EDA) y responder 4 preguntas de investigación
- Definir e implementar el tratamiento mediante Pipeline y ColumnTransformer (scikit-learn)
- Exportar un dataset final limpio y reproducible: `rendimiento_academico_limpio.csv`

## Caracterización del dataset

### Identificador

StudentID (no único: 5.000 valores para 5.100 filas)

### Variable objetivo

FinalGrade — escala oficial 1.0 a 10.0

### Variables numéricas (7)

Age, StudyHours, Attendance, PreviousGPA, AssignmentsCompleted, SleepHours, InternetHours

### Variables categóricas (2)

Scholarship (binaria), Program (5 carreras)

# Problemas de calidad detectados

Diagnóstico sobre el dataset crudo (5.100 registros × 11 variables)



## Valores faltantes

Entre 1.4% y 4.4% por variable predictora; ninguna variable supera el 5%. Patrón compatible con MCAR.



## Duplicados exactos

100 filas idénticas (2.0% del dataset): reingresos accidentales del mismo estudiante (StudentID repetido).



## Inconsistencias de dominio

59 registros con valores físicamente imposibles: asistencia <0% o >100%, horas de sueño negativas, +24 h de internet en un día; más 4 notas fuera de la escala 1–10.



## Formato categórico inconsistente

35 registros en Scholarship (7 variantes) y 36 en Program (12 variantes) por tildes, mayúsculas y espacios.

**Nota metodológica:** StudyHours es una variable semanal (dominio válido [0, 168] h, según Metadata.md), no diaria; se verificó contra ese rango y no presentó violaciones — no forma parte de los problemas de calidad anteriores.

# Valores atípicos (outliers)

Método del Rango Inter cuartílico (IQR) sobre las variables numéricas

## ¿Extremo válido o valor inválido?

El límite IQR ( $Q1 - 1.5 \cdot IQR$ ,  $Q3 + 1.5 \cdot IQR$ ) se aplicó a las 7 variables numéricas y a FinalGrade usando boxplots como evidencia gráfica. Antes de tratar los outliers, se corrigieron los valores de dominio inválidos (sección anterior): un valor físicamente imposible también aparece como estadísticamente extremo, por lo que ambos fenómenos deben separarse.

- Edad y horas de internet: colas largas de valores altos pero plausibles (estudiantes mayores, alto consumo) → outliers estadísticos genuinos.
- FinalGrade fuera de  $[1.0, 10.0]$ : inválido de dominio, no un outlier estadístico → tratado como error de captura (sección 2.4).
- Estrategia: winsorizar (capar) los valores extremos válidos a los límites IQR, sin eliminar al estudiante ni el resto de su información.



# 393

REGISTROS CON AL MENOS  
UN VALOR CAPADO POR IQR

Boxplots por variable numérica evidencian colas largas en Age e InternetHours; el resto muestra distribuciones más simétricas.

# Análisis exploratorio: distribuciones y correlaciones

Comportamiento de FinalGrade y su relación con las variables numéricas

## Distribución de FinalGrade


|                       |             |
|-----------------------|-------------|
| Media                 | 4.17        |
| Mediana               | 4.23        |
| Rango intercuartílico | 3.51 – 4.86 |

*Distribución aproximadamente simétrica en torno a la media, sin sesgo marcado hacia ningún extremo de la escala 1–10.*

## Variables categóricas

~2/3 de los estudiantes no posee beca. Ingeniería Informática concentra la mayor matrícula; Contador Auditor, la menor.

## Correlación de Pearson con FinalGrade



# Preguntas de investigación

Respuestas cuantificadas a partir del EDA

**P1**

## Beca vs. FinalGrade

Con beca: 4.37 promedio · Sin beca: 4.08. Diferencia de 0.30 puntos a favor de becados, estadísticamente significativa (t de Welch,  $p < 0.001$ ).

**P2**

## Programa académico

Ingeniería Informática lidera (4.23); Contador Auditor es el más bajo (4.05). Diferencia de solo 0.18 puntos: el programa explica poca variación.

**P3**

## StudyHours vs. FinalGrade

Relación positiva de intensidad moderada ( $r = 0.50$ ,  $p < 0.001$ ): más horas semanales de estudio se asocian a mejor nota, aunque el efecto es menor que el de otras variables.

**P4**

## Attendance vs. FinalGrade

Relación positiva y fuerte ( $r = 0.64$ ,  $p < 0.001$ ). El promedio sube de forma monótonica entre el cuartil de menor asistencia ( $\approx 3.31$ ) y el de mayor asistencia ( $\approx 4.94$ ).

# Estrategia de tratamiento

Decisiones fundamentadas en el diagnóstico de las secciones anteriores



## 1. Validar dominio

Convertir a NaN los valores físicamente imposibles: asistencia fuera de 0–100%, horas fuera de 0–24, notas fuera de la escala oficial 1–10.



## 2. Imputar y normalizar

Mediana en variables numéricas, moda en categóricas; texto normalizado a categorías canónicas (Sí/No, 5 programas).



## 3. Capar outliers (IQR)

Valores extremos pero válidos se winsorizan a los límites  $Q1 - 1.5 \cdot IQR$  /  $Q3 + 1.5 \cdot IQR$ , sin eliminar al estudiante.



## 4. Codificar y escalar

One-Hot Encoding para categóricas; StandardScaler para numéricas. FinalGrade se mantiene siempre separada.

Registros: se eliminan 100 duplicados exactos y 4 registros con FinalGrade fuera de la escala oficial [1.0, 10.0] (0.08%) antes de construir el pipeline — la variable objetivo nunca se imputa, para no introducir una fuga de información artificial.

# Implementación reproducible con Pipeline

scikit-learn: Pipeline + ColumnTransformer sobre las variables de entrada (X)



## Sub-pipeline numérico

1

`DomainRangeCleaner` → invalida (NaN) fuera de rango físico

2

`SimpleImputer(strategy="median")`

3

`IQRcapper(factor=1.5)` → winsoriza outliers

4

`StandardScaler()`

*Aplica a: Age, StudyHours, Attendance, PreviousGPA, AssignmentsCompleted, SleepHours, InternetHours*



## Sub-pipeline categórico

1

`CategoricalNormalizer` → unifica tildes/mayúsculas/espacios

2

`SimpleImputer(strategy="most_frequent")`

3

`OneHotEncoder(handle_unknown="ignore")`

*Aplica a: Scholarship, Program · Ambos sub-pipelines se combinan en un ColumnTransformer*

Transformadores personalizados (`BaseEstimator` + `TransformerMixin`), compatibles con `get_feature_names_out()`. `FinalGrade` se separa de X antes de todo el proceso, y el pipeline puede volver a ejecutarse sobre el CSV original con el mismo resultado.



# Dataset final y estado de calidad

Comparación entre el dataset original y el dataset tratado

| Indicador                           | Original | Tratado |
|-------------------------------------|----------|---------|
| Registros                           | 5.100    | 4.996   |
| Variables                           | 11       | 16*     |
| Valores faltantes                   | 1.335    | 0       |
| Registros duplicados                | 100      | 0       |
| Inconsistencias (dominio + formato) | 134      | 0       |
| Outliers sin tratar (IQR)           | 393      | 0       |

*\*Aumenta por la codificación One-Hot de Scholarship y Program (2 columnas → 7 columnas binarias).*

Verificación final: 0 nulos · 0 duplicados · 0 inconsistencias · 0 outliers extremos remanentes ( $|z| > 5$ )

# Conclusiones generales

Tres hallazgos sustentados en el EDA y el proceso de tratamiento



El cumplimiento de tareas, el rendimiento previo y la asistencia son los factores numéricos más asociados al rendimiento ( $r \approx 0.69, 0.66$  y  $0.64$ ); las horas de estudio semanales muestran una asociación más moderada ( $r \approx 0.50$ ).



Poseer beca se asocia con mejor rendimiento:  $+0.30$  puntos en promedio, diferencia estadísticamente significativa ( $p < 0.001$ ), aunque puede reflejar tanto un efecto directo como un sesgo de selección.



El programa académico explica poca variación en el rendimiento (solo  $0.18$  puntos entre el mejor y el peor promedio), muy por debajo de la brecha observada por beca.



## **rendimiento\_academico\_limpio.csv**

Dataset reproducible de 4.996 registros, listo para el desarrollo de modelos predictivos de rendimiento académico. Proceso ejecutable de principio a fin desde el CSV original.